

Registrazione learning-based del phantom cervicale senza punti fiduciali prescritti

Bozza della relazione tecnica e cronologia dello sviluppo

Giovanni Contursi

Altri componenti del gruppo da inserire

Stato del progetto: 22 settembre 2026

Sommario

Questo progetto studia la registrazione rigida tra un insieme parziale e non ordinato di punti acquisiti con un puntatore ottico e il digital twin di un phantom cervicale. Il metodo scelto è Deep Closest Point (DCP), che apprende descrittori e corrispondenze soft e ricava la trasformazione rigida mediante una testa SVD differenziabile. Sono considerate due modalità di acquisizione: uno *sweep* denso e connesso e un insieme *sparse* di pochi punti. Il confronto di riferimento è l'algoritmo clinico-esistente a quattro landmark con corrispondenze note, implementato mediante Procrustes/SVD.

Il lavoro non si è limitato a eseguire il codice DCP originale. È stato costruito un generatore sintetico specifico per la mesh del phantom, sono stati corretti diversi protocolli iniziali troppo favorevoli, è stata resa possibile la registrazione partial-to-global con cardinalità differenti, sono state introdotte metriche invarianti all'ordine, una baseline ufficiale, il calcolo della target registration error (TRE), controlli di riproducibilità e una supervisione geometrica opzionale sulle corrispondenze. I risultati attuali mostrano che la loss geometrica migliora nettamente la modalità sparse, mentre per lo sweep è necessario un peso più moderato. La baseline a quattro punti rimane molto più accurata, ma richiede landmark noti e un ordine di acquisizione prescritto; il metodo appreso affronta invece un problema più difficile e completamente non ordinato.

Indice

1	Contesto e obiettivo	3
1.1	Modalità di acquisizione	3
2	Fondamenti teorici	3
2.1	Registrazione rigida con corrispondenze note	3
2.2	Deep Closest Point	4
2.3	Metriche	4
3	Evoluzione del progetto	4
3.1	Analisi iniziale di traccia, articoli e modelli	5
3.2	Adattamento del codice DCP al phantom	5
3.3	Prima versione: corrispondenze implicite troppo facili	5
3.4	Permutazioni e metriche invarianti all'ordine	5
3.5	Campionamenti indipendenti	6
3.6	Passaggio definitivo a partial-to-global	6
3.7	Cardinalità diverse nella testa SVD	6
3.8	Stabilità con batch piccoli	6
3.9	Baseline ufficiale e target TRE	6
3.10	Supervisione geometrica delle corrispondenze	7
3.11	Riproducibilità e controlli	7

4	Architettura e protocollo attuale	7
4.1	Configurazione del modello	7
4.2	Generazione dei dati	8
4.3	Loss di posa	8
5	Risultati sperimentali disponibili	8
5.1	Come leggere i risultati	8
5.2	Ablation del peso della loss geometrica	9
5.3	Confronto con la baseline a quattro punti	9
5.4	Perché sparse è attualmente migliore di sweep	10
6	Problemi incontrati e conseguenze	10
7	Validazione sperimentale ancora necessaria	11
7.1	Ablation dell'acquisizione	11
7.2	Ripetizione su più seed di training	11
7.3	Test finale held-out	11
7.4	Bacino di convergenza e success rate	11
7.5	Robustezza al rumore	11
7.6	Reality check con Polaris	12
8	Struttura del codice	12
9	Conclusioni provvisorie	12
A	Cronologia sintetica	12
B	Esempio di comando riproducibile	13

1 Contesto e obiettivo

Il laboratorio dispone di un phantom fisico del distretto cervicale, del suo modello digitale triangolare e di un sistema di tracking ottico NDI Polaris Vega XT con puntatore calibrato. Il sistema attuale richiede di toccare quattro punti noti in un ordine prestabilito. Le quattro corrispondenze permettono di stimare in forma chiusa la trasformazione rigida dal frame Polaris al frame del phantom.

L'obiettivo del progetto è rimuovere due vincoli operativi:

- non richiedere punti anatomici prescritti;
- non richiedere un ordine di acquisizione noto.

L'operatore deve poter acquisire un insieme parziale e non ordinato di punti sulla superficie raggiungibile. La rete deve stimare la stessa trasformazione

$$\mathbf{x}_{\text{phantom}} = \mathbf{R}\mathbf{x}_{\text{Polaris}} + \mathbf{t}, \quad \mathbf{R} \in SO(3), \quad \mathbf{t} \in \mathbb{R}^3. \quad (1)$$

Tra le varianti proposte dalla traccia è stata scelta V2, Deep Closest Point (DCP), perché mantiene la soluzione SVD/Procrustes del metodo esistente ma sostituisce le corrispondenze imposte con corrispondenze apprese. Il confronto concettuale è quindi particolarmente diretto.

1.1 Modalità di acquisizione

Sono state implementate entrambe le modalità richieste:

Sweep. Una patch superficiale connessa, densa e locale. Nel protocollo iniziale vengono usati 512 punti e un raggio geodetico-euclideo di circa 20 mm attorno alla faccia seme.

Sparse. Un insieme non ordinato di punti sparsi sulla superficie. Nel protocollo iniziale vengono usati 25 punti, all'interno dell'intervallo 20–50 indicato dalla traccia.

Da completare: Verificare nella versione finale della relazione la terminologia della superficie acquisibile. La traccia parla di anatomia interna esposta, mentre un successivo chiarimento della docente ha indicato la superficie esterna (pelle). Gli esperimenti attuali usano `Prototipo_Scocca_Esterna.stl`, rinominata `phantom_surface.stl`. La scelta va documentata con il chiarimento ufficiale più recente.

2 Fondamenti teorici

2.1 Registrazione rigida con corrispondenze note

Dati due insiemi di punti corrispondenti $\{\mathbf{x}_i\}$ e $\{\mathbf{y}_i\}$, il problema classico consiste nel minimizzare

$$\min_{\mathbf{R}, \mathbf{t}} \sum_{i=1}^N \|\mathbf{y}_i - (\mathbf{R}\mathbf{x}_i + \mathbf{t})\|_2^2, \quad \mathbf{R}^\top \mathbf{R} = \mathbf{I}, \quad \det(\mathbf{R}) = 1. \quad (2)$$

Sottratti i centroidi, si costruisce la matrice di covarianza $\mathbf{H} = \sum_i (\mathbf{x}_i - \bar{\mathbf{x}})(\mathbf{y}_i - \bar{\mathbf{y}})^\top$. Dalla decomposizione $\mathbf{H} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^\top$ si ottiene

$$\mathbf{R} = \mathbf{V}\mathbf{D}\mathbf{U}^\top, \quad \mathbf{t} = \bar{\mathbf{y}} - \mathbf{R}\bar{\mathbf{x}}, \quad (3)$$

dove $\mathbf{D} = \text{diag}(1, 1, d)$ corregge le riflessioni e garantisce $\det(\mathbf{R}) = 1$ [1].

La baseline ufficiale usa esattamente questo algoritmo su quattro landmark noti. DCP usa lo stesso principio, ma sostituisce ogni target noto con un punto virtuale ottenuto dalle corrispondenze probabilistiche.

2.2 Deep Closest Point

DCP contiene tre blocchi principali [2]:

1. un estrattore di feature, nel nostro caso DGCNN;
2. un Transformer che scambia informazione tra source e target;
3. una testa SVD che trasforma le corrispondenze soft in $(\mathbf{R}, \mathbf{t})$.

Indichiamo con $\mathbf{F}_s \in \mathbb{R}^{d \times N_s}$ e $\mathbf{F}_t \in \mathbb{R}^{d \times N_t}$ gli embedding. I punteggi di corrispondenza sono

$$\mathbf{S} = \frac{\mathbf{F}_s^\top \mathbf{F}_t}{\sqrt{d}}, \quad \mathbf{W} = \text{softmax}_t(\mathbf{S}). \quad (4)$$

Per ogni punto source viene costruito un target virtuale

$$\hat{\mathbf{y}}_i = \sum_{j=1}^{N_t} W_{ij} \mathbf{y}_j. \quad (5)$$

La SVD è quindi applicata alle coppie $(\mathbf{x}_i, \hat{\mathbf{y}}_i)$. Questa formulazione supporta naturalmente $N_s \neq N_t$, condizione necessaria nel nostro protocollo: il source è parziale, mentre il target è il digital twin globale.

2.3 Metriche

Le metriche principali sono:

Errore di rotazione. Angolo della rotazione relativa $\mathbf{R}_{\text{pred}} \mathbf{R}_{\text{gt}}^\top$, espresso in gradi.

Errore di traslazione. Norma euclidea $\|\mathbf{t}_{\text{pred}} - \mathbf{t}_{\text{gt}}\|_2$, in millimetri.

Source proxy. Disaccordo medio, sui punti osservati, tra la trasformazione predetta e la trasformazione ground truth. È una metrica diagnostica e non deve essere confusa con la TRE anatomica.

TRE. Errore sui target clinicamente significativi. Ogni target, definito nel frame phantom, viene trasformato nel frame Polaris con l'inversa della ground truth e poi riportato nel phantom con la posa stimata:

$$e_k = \left\| \mathbf{R}_{\text{pred}} \mathbf{R}_{\text{gt}}^\top (\mathbf{p}_k - \mathbf{t}_{\text{gt}}) + \mathbf{t}_{\text{pred}} - \mathbf{p}_k \right\|_2. \quad (6)$$

Per ogni metrica vengono riportati media, deviazione standard, mediana, 95-esimo percentile e massimo. Media e mediana descrivono il caso tipico; p_{95} e massimo evidenziano le code e i fallimenti.

3 Evoluzione del progetto

Questa sezione documenta anche i tentativi che non sono entrati nel protocollo finale. Sono importanti perché spiegano le scelte metodologiche e impediscono di interpretare come reali risultati ottenuti su problemi troppo semplici.

3.1 Analisi iniziale di traccia, articoli e modelli

Il lavoro è iniziato dall'analisi della traccia, dell'articolo DCP, del metodo least-squares/SVD e dei componenti STL del phantom. In questa fase sono stati chiariti:

- la direzione della trasformazione, Polaris $\rightarrow$ phantom;
- l'uso dei millimetri nel frame fisico;
- la necessità di confrontare DCP e baseline sulla stessa TRE;
- la separazione obbligatoria tra sweep e sparse;
- la necessità di non usare quattro vertici casuali come baseline.

Inizialmente mancavano le coordinate ufficiali dei quattro landmark e dei target TRE. Per evitare una baseline artificiale, tali campi sono rimasti vuoti fino alla consegna del codice di registrazione e delle coordinate da parte dei docenti.

3.2 Adattamento del codice DCP al phantom

Il codice di riferimento DCP era progettato per dataset generici di point cloud. È stato introdotto `PhantomDataset`, che:

- carica e valida la mesh STL con `trimesh`;
- elimina triangoli degeneri e verifica coordinate e aree finite;
- campiona uniformemente punti sulle facce usando coordinate baricentriche corrette;
- costruisce il grafo di adiacenza delle facce per generare patch connesse nello sweep;
- genera trasformazioni rigide casuali con rotazioni Euler e traslazioni limitate;
- simula il source nel frame Polaris e aggiunge rumore gaussiano;
- normalizza le coordinate fisiche mediante una scala comune di 100 mm.

Il test geometrico standalone verifica che la ground truth sia internamente coerente e visualizza la posizione della patch sulla mesh.

3.3 Prima versione: corrispondenze implicite troppo facili

Nella prima implementazione source e target contenevano gli stessi punti, nello stesso ordine, prima e dopo la trasformazione. Il modello poteva quindi sfruttare una corrispondenza uno-a-uno nascosta. Un test di overfitting produsse circa 0.20° di errore di rotazione e 0.39 mm di errore di traslazione, ma il dato non rappresentava il problema operativo richiesto.

La conseguenza è metodologicamente importante: un errore basso non è sufficiente a dimostrare la correttezza del protocollo. È necessario che il dataset non fornisca accidentalmente alla rete l'informazione che dovrebbe imparare.

3.4 Permutazioni e metriche invarianti all'ordine

Source e target sono stati successivamente permutati in modo indipendente. Questo ha fatto emergere un secondo problema: le metriche MSE/MAE iniziali confrontavano direttamente `transformed_src` con `target`. Tale confronto è valido soltanto se i punti sono corrispondenti e ordinati.

Le metriche di training e validation sono state corrette confrontando la trasformazione predetta e la ground truth applicate allo stesso insieme di punti. Per il verso diretto, ad esempio,

$$\text{MSE}_{AB} = \frac{1}{3N_s} \sum_i \|(\mathbf{R}_{\text{pred}}\mathbf{x}_i + \mathbf{t}_{\text{pred}}) - (\mathbf{R}_{\text{gt}}\mathbf{x}_i + \mathbf{t}_{\text{gt}})\|_2^2. \quad (7)$$

In questo modo la metrica misura davvero l'errore di posa e non dipende dall'ordine o dalla discretizzazione delle point cloud.

3.5 Campionamenti indipendenti

È stato poi rimosso il riutilizzo delle stesse coordinate geometriche tra source e target. Un test di overfitting su point set indipendenti ma relativi alla stessa regione diede circa 0.35° e 0.69 mm . Il risultato confermava che l'architettura e la SVD erano addestrabili, ma il problema era ancora locale-locale e non coincideva con la registrazione richiesta.

3.6 Passaggio definitivo a partial-to-global

La modifica più importante è stata definire correttamente i due ingressi:

- **source**: acquisizione parziale, 512 punti sweep oppure 25 punti sparse, espressa nel frame Polaris e affetta da rumore;
- **target**: discretizzazione globale del digital twin, 1024 punti nel frame phantom.

Il target globale viene creato una volta con Farthest Point Sampling (FPS) a partire da un insieme più ampio di candidati uniformi. Il seed dedicato rende la discretizzazione deterministica. Il target viene inoltre salvato nel checkpoint e ripristinato durante la valutazione: training, validation e test usano così esattamente lo stesso digital twin.

Il passaggio a partial-to-global ha aumentato notevolmente la difficoltà. I primi smoke test mostrarono errori anche superiori a 100 mm ; ciò non era un semplice peggioramento del modello, ma la conseguenza del passaggio dal problema artificiale con corrispondenze implicite al problema reale con overlap parziale e molte ambiguità.

3.7 Cardinalità diverse nella testa SVD

La testa SVD originale assumeva implicitamente cardinalità compatibili. È stata riscritta per produrre una matrice di punteggi $N_s \times N_t$ e un target virtuale per ciascun punto source. È stata inoltre aggiunta la correzione esplicita delle riflessioni per garantire $\det(\mathbf{R}) = +1$. Questa modifica consente, ad esempio, di registrare 25 punti sparse contro 1024 punti del digital twin.

3.8 Stabilità con batch piccoli

I primi esperimenti di overfitting mostrarono una forte differenza tra training e validation. Una delle cause era l'uso di Batch Normalization con batch molto piccoli. Nel backbone DGCNN la BatchNorm è stata sostituita con GroupNorm, scegliendo automaticamente il maggior numero di gruppi compatibile fino a otto. La GroupNorm non dipende dalle statistiche correnti del batch e ha reso più coerenti training ed evaluation.

3.9 Baseline ufficiale e target TRE

Dopo la consegna del codice di registrazione dei docenti sono stati inseriti i quattro landmark ufficiali nel frame phantom:

$$\begin{aligned} (2.5, -65.0, 82.5), & \quad (50.0, -65.0, 77.5), \\ (50.0, 25.0, 50.0), & \quad (42.5, 102.5, 27.5) \quad [\text{mm}]. \end{aligned} \quad (8)$$

Per ogni campione i landmark vengono portati nel frame Polaris con l'inversa della ground truth, viene aggiunto lo stesso rumore del tracker e la posa è stimata con SVD classica. La baseline e DCP sono quindi valutati sugli stessi campioni e sugli stessi target TRE.

Sono stati definiti cinque target lungo la regione centrale cervicale, con particolare attenzione alla zona del midollo. La correttezza matematica della pipeline è verificata con casi sintetici: recupero esatto senza rumore, TRE nullo, traslazione di 1 mm e rotazione nota di 90° .

3.10 Supervisione geometrica delle corrispondenze

La sola pose loss supervisiona l'uscita finale ma non impone direttamente che la matrice di attenzione rappresenti corrispondenze geometriche sensate. È stata quindi aggiunta una loss opzionale.

La ground truth allinea ogni punto source nel frame phantom. Le distanze dai punti del target costruiscono una distribuzione soft

$$q_{ij} = \text{softmax}_j \left(-\frac{\|\mathbf{R}_{gt}\mathbf{x}_i + \mathbf{t}_{gt} - \mathbf{y}_j\|^2}{2\sigma^2} \right), \quad (9)$$

con $\sigma = 5$ mm. La rete produce $p_{ij} = \text{softmax}_j(S_{ij})$ e viene minimizzata

$$\mathcal{L}_{corr} = D_{KL}(q\|p). \quad (10)$$

L'obiettivo totale è

$$\mathcal{L}_{tot} = \mathcal{L}_{pose} + 0.1\mathcal{L}_{cycle} + \lambda_{corr}\mathcal{L}_{corr}, \quad (11)$$

dove il termine di ciclo è presente soltanto se richiesto. La ground truth è usata esclusivamente per costruire la loss durante l'addestramento e non viene fornita agli ingressi della rete. Il checkpoint migliore continua a essere selezionato sulla pose validation loss, senza includere la KL, per non favorire un modello che predice buone corrispondenze ma una posa peggiore.

3.11 Riproducibilità e controlli

Sono stati aggiunti:

- seed deterministici per campione e split separati;
- salvataggio di argomenti, ottimizzatore, scheduler, epoca, digital twin e hash SHA-256 della mesh;
- distinzione tra `-resume` e `-pretrained`;
- blocco della sovrascrittura accidentale di esperimenti esistenti;
- backup dei file sorgente nella directory di ogni esperimento;
- clipping del gradiente e controlli su valori non finiti;
- otto unit test su forward/backward, scale, permutazioni, corrispondenze, checkpoint, dataset, SVD e TRE.

Tutti gli otto test risultano superati sia su Windows sia sul computer Linux usato per i training GPU.

4 Architettura e protocollo attuale

4.1 Configurazione del modello

La configurazione principale usa:

Tabella 1: Configurazione DCP principale.

Componente	Configurazione
Backbone	DGCNN, $k = 20$
Dimensione embedding	512
Pointer	Transformer, 1 blocco, 4 teste
Feed-forward	1024 unità
Dropout	0
Testa	SVD differenziabile
Parametri addestrabili	5 568 896
Normalizzazione	GroupNorm

4.2 Generazione dei dati

Per ciascun indice del dataset viene creato un generatore indipendente a partire da `SeedSequence([seed, index])`. Ciò rende ogni campione riproducibile senza riutilizzare la stessa sequenza casuale.

I parametri finora usati nei training principali sono:

Tabella 2: Protocollo sintetico di riferimento.

Parametro	Valore
Rotazione massima per asse	$0.17 \text{ rad } (\approx 9.74^\circ)$
Traslazione massima per asse	10 mm
Rumore per coordinata	$\sigma = 0.3 \text{ mm}$
Scala rete	100 mm
Target globale	1024 punti FPS
Sweep iniziale	512 punti, raggio 20 mm
Sparse iniziale	25 punti
Training / validation	5000 / 500 campioni
Epoche	50
Ottimizzatore	Adam, 10^{-3} , weight decay 10^{-4}
Scheduler	StepLR, fattore 0.5 dopo 25 epoche
Gradient clipping	norma massima 1

4.3 Loss di posa

La loss di rotazione non confronta direttamente gli elementi di due matrici arbitrarie, ma misura quanto la rotazione relativa si discosta dall'identità:

$$\mathcal{L}_R = \text{MSE}(\mathbf{R}_{pred}^\top \mathbf{R}_{gt}, \mathbf{I}), \quad \mathcal{L}_t = \text{MSE}(\mathbf{t}_{pred}, \mathbf{t}_{gt}). \quad (12)$$

Le traslazioni sono espresse nelle unità normalizzate della rete durante il training e convertite una sola volta in millimetri durante l'evaluation.

5 Risultati sperimentali disponibili

5.1 Come leggere i risultati

I valori di validation loss sono utili per selezionare checkpoint all'interno dello stesso protocollo, ma non sono direttamente interpretabili come millimetri. La metrica primaria del progetto è la TRE in evaluation su campioni held-out. Gli esperimenti iniziali con source e target corrispondenti sono considerati test di debug e non risultati finali.

5.2 Ablation del peso della loss geometrica

Il peso λ_{corr} è stato confrontato sullo stesso development set di 2000 campioni, seed 44. In questo modo la differenza è attribuibile al modello e non a campioni casuali differenti.

Tabella 3: Ablation di λ_{corr} in modalità sweep, development seed 44. Tutti gli errori lineari sono in millimetri.

λ_{corr}	Rot. media [deg]	Trasl. media	Proxy medio	TRE media	TRE mediana	TRE p_{95}	TRE max
0.00	7.963	12.971	17.801	14.028	13.390	24.843	45.863
0.01	8.067	13.351	17.281	14.061	13.258	25.815	52.394
0.03	7.631	12.504	13.931	12.761	11.582	24.660	57.856
0.10	7.771	13.421	11.991	13.433	11.903	27.260	90.501

Per lo sweep, $\lambda_{corr} = 0.03$ è il compromesso migliore. Rispetto a $\lambda = 0$, la TRE media scende da 14.028 a 12.761 mm, un miglioramento di circa il 9%, e la mediana migliora di circa il 13.5%. Il peso 0.1 ottiene il proxy migliore ma peggiora media, p_{95} e soprattutto il massimo. Ciò indica che una supervisione troppo forte può ottimizzare le corrispondenze locali senza garantire la robustezza della posa globale.

Tabella 4: Ablation di λ_{corr} in modalità sparse, development seed 44. Tutti gli errori lineari sono in millimetri.

λ_{corr}	Rot. media [deg]	Trasl. media	Proxy medio	TRE media	TRE mediana	TRE p_{95}	TRE max
0.00	3.947	5.485	8.333	5.440	5.152	9.539	15.988
0.01	3.394	4.270	6.585	4.061	3.724	7.739	18.519
0.03	3.174	3.996	5.994	3.653	3.321	7.105	18.310
0.10	3.073	3.899	5.838	3.605	3.226	7.062	17.142

Per la modalità sparse il comportamento è più netto: aumentando il peso fino a 0.1 migliorano tutte le statistiche aggregate. Rispetto a $\lambda = 0$, la TRE media migliora di circa il 33.7%, la mediana del 37.4% e il p_{95} del 26.0%. Il massimo resta leggermente peggiore del modello senza KL, ma 0.1 è anche il migliore tra tutti i modelli supervisionati nelle code.

Le configurazioni provvisoriamente selezionate sono quindi:

- sweep: $\lambda_{corr} = 0.03$;
- sparse: $\lambda_{corr} = 0.10$.

5.3 Confronto con la baseline a quattro punti

Sul development set seed 44, la baseline presenta una TRE media di circa 0.40 mm in entrambe le modalità. Tale risultato è coerente con il vantaggio di conoscere quattro corrispondenze esatte e ben distribuite. Il confronto sintetico corrente è riassunto in Tabella 5.

Tabella 5: Migliori configurazioni correnti sul development set seed 44.

Modalità	Metodo	Rot. [deg]	Trasl. [mm]	TRE [mm]	TRE p_{95} [mm]
Sweep	DCP, $\lambda = 0.03$	7.631	12.504	12.761	24.660
Sweep	Baseline 4 punti	0.435	0.561	0.401	0.792
Sparse	DCP, $\lambda = 0.10$	3.073	3.899	3.605	7.062
Sparse	Baseline 4 punti	0.434	0.564	0.401	0.795

La baseline è dunque ancora nettamente più accurata. Tuttavia i due metodi non richiedono lo stesso intervento: la baseline usa soltanto quattro punti ma con identità e ordine noti; DCP

usa punti arbitrari e non ordinati. Il risultato va presentato senza sostenere che DCP abbia già sostituito la baseline in termini di accuratezza. Il contributo attuale è la rimozione dei vincoli di acquisizione, con un costo ancora significativo in TRE.

5.4 Perché sparse è attualmente migliore di sweep

A prima vista può sembrare sorprendente che 25 punti sparse superino uno sweep di 512 punti. Nel generatore corrente, però, i punti sparse sono distribuiti sull'intera superficie, mentre lo sweep occupa una singola patch locale. Una patch della scocca può essere liscia, quasi simmetrica o geometricamente poco distintiva. Molti punti nella stessa zona non aggiungono necessariamente informazione globale. Pochi punti distanti tra loro possono invece vincolare meglio rotazione e traslazione.

Questa osservazione ha motivato l'ablation attualmente in esecuzione su:

- raggio dello sweep: 20, 40 e 60 mm;
- numero di punti sparse: 20, 25, 35 e 50;
- confronto, per ogni acquisizione, tra pose loss standard e migliore loss geometrica selezionata per la modalità.

Da completare: Inserire qui la tabella dell'ablation di acquisizione al termine del training `acq_sweep_r40_dcp_seed42` e degli esperimenti successivi. Non selezionare il protocollo finale prima di aver confrontato tutti i risultati sullo stesso development seed.

6 Problemi incontrati e conseguenze

Tabella 6: Principali problemi tecnici e metodologici affrontati.

Problema	Correzione	Conseguenza
Percorso STL errato	Individuazione dei file reali in ModelloPhantom e uso di percorsi quotati	Pipeline eseguibile su Windows e Linux; scelta esplicita della mesh.
Baseline con vertici casuali	Attesa delle coordinate ufficiali e implementazione del metodo SVD dei docenti	Confronto difendibile e coerente con il sistema esistente.
Source e target identici	Permutazioni, campionamenti indipendenti e infine target globale FPS	Eliminazione delle corrispondenze implicite; problema più realistico ma più difficile.
Metriche pointwise non valide	Confronto tra trasformazione predetta e GT applicate agli stessi punti	MSE e MAE invarianti all'ordine.
Cardinalità source/-target diverse	Matrice di attenzione $N_s \times N_t$ e target virtuali source-to-target	Supporto per 25/512 punti contro 1024.
Gap train/eval con batch piccoli	BatchNorm sostituita da Group-Norm	Comportamento più stabile e checkpoint più affidabili.
Digital twin ricampionato	Target FPS fisso salvato nel checkpoint	Riproducibilità tra training, validation e test.
Unità mm / unità rete	Normalizzazione unica e conversione esplicita in evaluation	Errori fisici interpretabili e riduzione dei rischi di fattori 100 o 1000.

Problema	Correzione	Conseguenza
Attenzione non supervisionata	KL geometrica con etichette soft	Grande miglioramento sparse; peso da calibrare nello sweep.
Esperimenti sovrascrivibili	Blocco su directory esistenti, backup sorgenti, checkpoint best/last	Maggiore tracciabilità; le cartelle incomplete devono essere riprese o archiviate esplicitamente.

7 Validazione sperimentale ancora necessaria

Prima di considerare chiusa la parte sperimentale sono previste le seguenti attività.

7.1 Ablation dell'acquisizione

L'esperimento in corso deve determinare se le prestazioni cambiano con una patch sweep più estesa e con un numero maggiore di punti sparse. I parametri devono essere scelti sul development set, non sul test finale.

7.2 Ripetizione su più seed di training

Una sola inizializzazione non consente di distinguere una scelta robusta da un risultato fortunato. Dopo aver fissato raggio e numero di punti, le quattro configurazioni principali dovranno essere ripetute con almeno tre seed di training:

- sweep senza loss geometrica;
- sweep con $\lambda_{corr} = 0.03$;
- sparse senza loss geometrica;
- sparse con $\lambda_{corr} = 0.10$.

La relazione finale dovrà riportare media e deviazione tra seed, oltre alle statistiche per campione.

7.3 Test finale held-out

Il seed finale deve rimanere inutilizzato durante le scelte progettuali. La procedura proposta usa:

- seed 44 per sviluppo e ablation;
- seed di training distinti, ad esempio 42, 123 e 777;
- seed 314159 per la sola valutazione finale.

7.4 Bacino di convergenza e success rate

La traccia richiede di studiare il disallineamento iniziale entro il quale il metodo converge. Occorre valutare più livelli di rotazione e traslazione, ad esempio aumentando separatamente i limiti, e definire prima dell'esperimento una soglia di successo basata sulla TRE. Un esempio da discutere è $TRE < 5\text{ mm}$, ma la soglia finale dovrebbe essere motivata clinicamente o concordata con la docente.

7.5 Robustezza al rumore

È opportuno confrontare almeno $\sigma = 0, 0.3$ e 0.6 mm . Questo permette di separare l'errore dovuto all'ambiguità geometrica da quello dovuto al tracker.

7.6 Reality check con Polaris

Il limite principale è l'assenza, al momento, di una piccola acquisizione reale sul phantom. La traccia richiede un controllo finale con Polaris. I risultati sintetici non dimostrano da soli la generalizzazione a errori reali di calibrazione, contatto, occlusione e campionamento manuale.

8 Struttura del codice

phantom_data.py Caricamento mesh, validazione, campionamento uniforme, grafo delle facce, patch sweep, FPS, trasformazioni casuali e dataset partial-to-global.

model.py DGCNN/PointNet, Transformer, testa SVD e modello DCP. Contiene GroupNorm e supporto opzionale alla restituzione dei logits di corrispondenza.

correspondence_loss.py Costruzione delle etichette geometriche soft e KL $D_{KL}(q||p)$.

train.py Training e validation, loss di posa/ciclo/KL, checkpoint, backup dei sorgenti, resume/pretrained, logging e TensorBoard.

evaluate.py Ricostruzione della configurazione dal checkpoint, metriche fisiche, TRE, baseline ufficiale e riepilogo statistico.

test_correspondence.py Otto test automatici della pipeline.

util.py Trasformazioni di point cloud e conversioni di rotazione.

9 Conclusioni provvisorie

Il progetto ha raggiunto una pipeline completa e verificata per la registrazione sintetica partial-to-global del phantom cervicale. Il progresso più rilevante non è un singolo valore di loss, ma il passaggio da un test iniziale con corrispondenze implicite a un protocollo realistico, non ordinato, con overlap parziale, digital twin globale fisso, baseline ufficiale e TRE anatomica.

I risultati attuali supportano tre conclusioni:

1. la supervisione geometrica delle corrispondenze è utile, soprattutto nella modalità sparse;
2. uno sweep locale molto denso può essere meno informativo di pochi punti distribuiti globalmente;
3. la baseline a quattro landmark rimane molto più accurata, ma paga tale accuratezza con corrispondenze e ordine prescritti.

Il progetto non deve quindi essere presentato come una vittoria numerica di DCP sulla baseline. La domanda scientifica corretta è quanto errore si accetta per eliminare la procedura vincolata dei quattro landmark e quali modalità di acquisizione rendono questo compromesso più favorevole. Le prossime ablation, la valutazione multi-seed e il reality check Polaris serviranno a rispondere in modo più solido.

A Cronologia sintetica

Fase	Attività principale
Analisi	Studio della traccia, DCP, soluzione SVD e componenti STL.
Dataset V1	Generazione di coppie sintetiche da mesh; verifica di frame, scala e rumore.

Fase	Attività principale
Debug	Overfitting su pochi campioni e controllo che la SVD fosse differenziabile e stabile.
Unordered	Permutazione dei punti e correzione delle metriche non invarianti all'ordine.
Independent	Rimozione del riuso delle stesse coordinate tra point set.
Partial-to-global	Source parziale contro digital twin globale FPS da 1024 punti.
Stabilità	GroupNorm, gradient clipping e controlli sui valori non finiti.
Baseline	Inserimento dei quattro landmark ufficiali e SVD classica.
TRE	Inserimento dei target, metriche per target e test matematici.
Supervisione	Loss KL geometrica sulle corrispondenze source-to-target.
Ablation loss	Confronto $\lambda \in \{0, 0.01, 0.03, 0.10\}$ sul seed 44.
Ablation acquisizione	Confronto in corso di raggi sweep e cardinalità sparse.
Fase finale	Multi-seed, robustezza, basin of attraction, success rate e dati Polaris reali.

B Esempio di comando riproducibile

Il seguente comando mostra la configurazione base di un training sweep con supervisione geometrica. I valori definitivi di raggio e peso dovranno essere aggiornati dopo le ablation.

```
python train.py \
  --stl phantom_surface.stl \
  --exp_name sweep_corr003_seed42 \
  --emb_nn dgcnn --pointer transformer --head svd \
  --emb_dims 512 --ff_dims 1024 \
  --n_blocks 1 --n_heads 4 --dgcnn_k 20 \
  --batch_size 2 --epochs 50 --scheduler 25 \
  --lr 0.001 --grad_clip 1 \
  --dset_mode sweep \
  --dset_num_samples 5000 --val_num_samples 500 \
  --dset_n_points 512 --target_n_points 1024 \
  --dset_rot_max 0.17 --dset_trans_max 10 \
  --noise_sigma 0.3 --network_scale_mm 100 \
  --patch_radius_mm 20 --manualSeed 42 \
  --num_workers 4 --corr_weight 0.03 \
  --corr_sigma_mm 5
```

Riferimenti bibliografici

- [1] K. S. Arun, T. S. Huang, S. D. Blostein, “Least-Squares Fitting of Two 3-D Point Sets,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. PAMI-9, no. 5, 1987.
- [2] Y. Wang, J. M. Solomon, “Deep Closest Point: Learning Representations for Point Cloud Registration,” *Proceedings of ICCV*, 2019.
- [3] P. J. Besl, N. D. McKay, “A Method for Registration of 3-D Shapes,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 14, no. 2, 1992.