MEDICAL ROBOTICS · PROGETTO DI FINE CORSO · A.A. 2025/2026

Registrazione learning-based del phantom cervicale

senza punti fiduciali prescritti — Deep Closest Point (variante V2)

Flavio Massaroni · Giovanni Contursi

Repository: flaviomassaroni/learning-based-phantom-registration

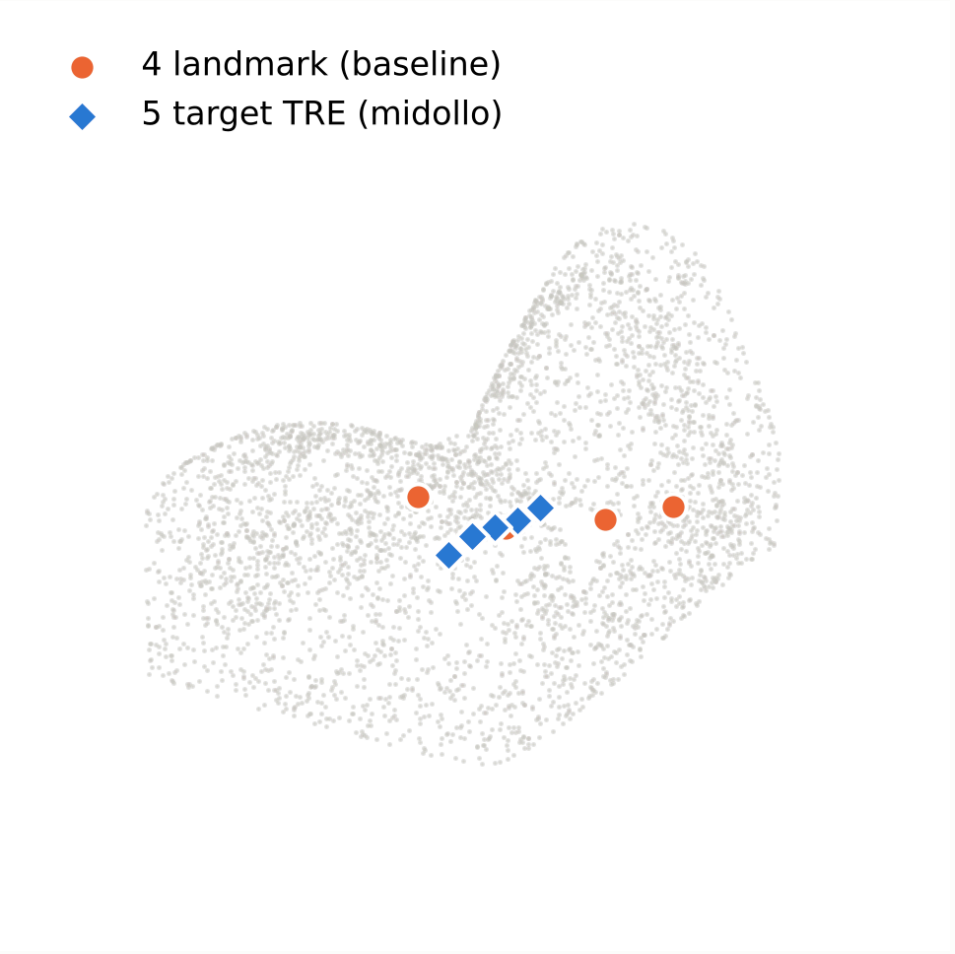
1 · CONTESTO

Il punto di partenza: registrazione a 4 landmark

- Phantom fisico del distretto cervicale + **digital twin** (mesh triangolare, ≈173k vertici).
- Tracker ottico **NDI Polaris Vega XT** con puntatore calibrato (pivot).
- Metodo attuale: si toccano **4 punti noti** in un **ordine prestabilito** → trasformazione rigida in forma chiusa (SVD / Procrustes).

> **Obiettivo del progetto:** stesso hardware, ma l'operatore acquisisce un insieme di punti **parziale e non ordinato**; una rete stima la stessa trasformazione Polaris → phantom.

$$x_{\text{phantom}} = R \cdot x_{\text{Polaris}} + t, \quad R \in SO(3),\ t \in \mathbb{R}^3$$



Registrazione rigida con corrispondenze note (Arun, 1987)

$$\min_{R,t} \Sigma_i \| y_i - (R\, x_i + t) \|^2$$

1. Si sottraggono i baricentri $\bar{x}$, $\bar{y}$ (disaccoppia R e t).
2. Matrice di covarianza $\mathbf{H = \Sigma\, (x_i - \bar{x})(y_i - \bar{y})^T = U\Sigma V^T}$
3. $\mathbf{R = V \cdot diag(1,1,d) \cdot U^T}$, con d = det(VU^T) per evitare riflessioni
4. $\mathbf{t = \bar{y} - R\, \bar{x}}$

Se le corrispondenze non sono note?

Problema "uovo-gallina": per trovare le corrispondenze serve (R, t), per trovare (R, t) servono le corrispondenze.

- **ICP** alterna i due passi → sensibile all'inizializzazione, minimi locali.
- **Go-ICP** globalmente ottimo ma lentissimo.
- **Descrittori + RANSAC**: due stadi, non end-to-end.
- **DCP**: corrispondenze *apprese*, SVD differenziabile, end-to-end.

Primo passo del lavoro: studio della traccia, dell'articolo DCP e di Arun et al. (note in `Papers/notes.md` e `dcp-master.md`).

Tre varianti proposte: perché V2 – Deep Closest Point

V1 · PointNetLK

Correspondence-free: descrittore globale PointNet + Lucas–Kanade iterativo.

Robusto su sparse, sensibile a grandi disallineamenti.

V2 · Deep Closest Point ✔

Embedding appresi + attenzione → **corrispondenze soft** → **SVD differenziabile**.

È lo **stesso Procrustes** della baseline: cambia solo che le corrispondenze sono apprese invece che imposte dall'ordine di tocco.

V3 · FCGF + RANSAC + ICP

Descrittori 3D densi, matching + RANSAC, raffinamento ICP.

Forte su sweep, debole su sparse.

Il confronto concettuale con il metodo esistente è il più diretto: **baseline = SVD su 4 corrispondenze esatte**, **DCP = SVD su corrispondenze apprese** da punti arbitrari.

4 · ARCHITETTURA

Come funziona DCP

Input
source parziale (Polaris)
target = digital twin

→

DGCNN
grafo k-NN (k=20), feature locali, pesi condivisi, emb 512

→

Transformer
self + cross attention: ogni cloud "guarda" l'altra

→

Soft matching
softmax dei punteggi $N_s \times N_t$

→

SVD head
Procrustes differenziabile → R, t

$$S = F_s^{\top} F_t / \sqrt{d}, \quad W = \mathrm{softmax}_t(S)$$

$$\hat{y}_i = \Sigma_j \, W_{ij} \, y_j \quad \text{(punto target "virtuale")}$$

La SVD viene applicata alle coppie $(x_i, \hat{y}_i)$: funziona anche con **$N_s \neq N_t$**.

Loss di posa

$$L_R = \mathrm{MSE}(R_{pred}^{\top} R_{gt}, I) \qquad L_t = \mathrm{MSE}(t_{pred}, t_{gt})$$

Configurazione finale: DGCNN + Transformer (1 blocco, 4 teste, FF 1024) + SVD head, **5.57 M parametri**.

5 · DATI

Dati sintetici dal digital twin: due modalità di acquisizione



Generazione di ogni campione

1. Campionamento uniforme sulla superficie (coordinate baricentriche).
2. Trasformazione rigida casuale: ±0.17 rad (≈9.7°) e ±10 mm per asse.
3. Rumore gaussiano del tracker σ = 0.3 mm.
4. Normalizzazione delle coordinate: scala comune 100 mm.

Le due modalità (asse sperimentale richiesto)

- **Sweep**: patch connessa e densa (512 pt) costruita sul grafo di adiacenza delle facce, raggio 20–60 mm.
- **Sparse**: 20–50 punti sparsi, non ordinati.
- Superficie usata: `Prototipo_Scocca Esterna.stl`.

Le tappe che ci hanno portato alla versione finale

STEP 1
Adattamento DCP
PhantomDataset al posto di ModelNet40, mesh STL, frame e mm

STEP 2
Prima versione
source e target uguali: errore bassissimo… ma ingannevole

STEP 3
Punti non ordinati
permutazioni + metriche invarianti all'ordine

STEP 4
Campionamenti indipendenti
niente più coordinate condivise tra source e target

STEP 5
Partial-to-global
source parziale vs digital twin globale FPS da 1024 pt

STEP 6
Stabilità
SVD per $N_s \neq N_t$, GroupNorm, gradient clipping

STEP 7
Baseline + TRE
4 landmark ufficiali, 5 target lungo il midollo

STEP 8
Loss KL geometrica
supervisione diretta delle corrispondenze

STEP 9
Riproducibilità
seed, checkpoint completi, 8 unit test

STEP 10
Ablation
peso λ della KL, raggio sweep, numero punti sparse

Filo conduttore: **ogni volta che il risultato sembrava "troppo buono", il protocollo era troppo facile.** Abbiamo reso il problema progressivamente più realistico.

STEP 1

Adattare il codice DCP al phantom

Il codice originale (`dcp-master/`) era pensato per ModelNet40. Nuova cartella `phantom_v2/` con `PhantomDataset`, che:

- carica e valida la mesh STL con `trimesh` (facce degeneri rimosse, aree finite);
- campiona uniformemente sulle facce;
- costruisce il grafo di adiacenza delle facce per le patch sweep;
- genera trasformazioni rigide note (e le loro inverse);
- simula il source nel frame Polaris con rumore;
- normalizza i mm in unità di rete.

Chiarimenti fatti in questa fase

- Direzione della trasformazione: **Polaris → phantom**.
- Unità fisiche in **millimetri**.
- DCP e baseline valutati sulla **stessa TRE**.
- Sweep e sparse tenuti **separati**.
- Niente baseline su 4 vertici casuali: si attendono le coordinate ufficiali.

Problema pratico risolto: percorso STL errato → file reali in `ModelloPhantom/`, script `unify.py` per unire le mesh.

STEP 2 · 3 · 4

Rendere il problema onesto

2 Corrispondenze implicite

Source e target contenevano **gli stessi punti, nello stesso ordine**.

Overfitting: **0.20°** e **0.39 mm**.

La rete poteva sfruttare una corrispondenza 1-a-1 nascosta: non è il problema reale.

3 Permutazioni

Source e target permutati in modo indipendente.

Le metriche MSE/MAE confrontavano `transformed_src` con `target` punto a punto → **valide solo se ordinati**.

Nuova metrica: posa predetta vs GT applicate agli **stessi punti**.

4 Campionamenti indipendenti

Source e target campionati separatamente sulla stessa regione.

Overfitting: **0.35°** e **0.69 mm**.

L'architettura è addestrabile, ma il problema è ancora locale-locale.

$$\mathrm{MSE}_{\mathrm{AB}} = 1/(3N_s)\ \Sigma_i \left\| (R_{\mathrm{pred}} x_i + t_{\mathrm{pred}}) - (R_{\mathrm{gt}} x_i + t_{\mathrm{gt}}) \right\|^2$$

Lezione: un errore basso non dimostra che il protocollo sia corretto. Il dataset non deve "regalare" alla rete l'informazione che dovrebbe imparare.

STEP 5

Il passaggio decisivo: partial-to-global

- **Source**: acquisizione parziale (512 pt sweep oppure 20–50 pt sparse), frame Polaris, con rumore.
- **Target**: discretizzazione **globale** del digital twin, 1024 punti, frame phantom.
- Target creato **una sola volta** con Farthest Point Sampling da un insieme più ampio di candidati, con seed dedicato.
- Salvato nel **checkpoint**: training, validation e test usano esattamente lo stesso digital twin.

Effetto immediato

Primi smoke test con errori anche **> 100 mm**.

Non era un peggioramento del modello: era il passaggio dal problema artificiale al problema reale, con overlap parziale e molte ambiguità.

> Da qui in poi tutti i numeri si riferiscono al problema **realistico**.

STEP 6

Modifiche all'architettura per la stabilità

SVD head $N_s \times N_t$

La testa originale assumeva cardinalità compatibili. Riscritta per produrre una matrice di punteggi $N_s \times N_t$ e un target virtuale per ogni punto source.

Correzione esplicita delle riflessioni: **det(R) = +1**.

Ora 25 punti si registrano contro 1024.

BatchNorm → GroupNorm

Con batch molto piccoli (batch size 2) la BatchNorm creava un forte gap train/validation.

In DGCNN si usa GroupNorm (fino a 8 gruppi): non dipende dalle statistiche del batch.

Unità e training

Normalizzazione unica (100 mm) e conversione esplicita in mm solo in evaluation → niente errori di fattore 100/1000.

Gradient clipping (norma 1) e controlli sui valori non finiti.

STEP 7

Baseline ufficiale e Target Registration Error

Baseline a 4 landmark

Coordinate ufficiali fornite dai docenti (frame phantom, mm):

`(2.5, −65, 82.5)` `(50, −65, 77.5)`
`(50, 25, 50)` `(42.5, 102.5, 27.5)`

Per ogni campione: landmark portati nel frame Polaris con la GT inversa, **stesso rumore** del tracker, posa stimata con SVD classica.

DCP e baseline valutati sugli **stessi campioni** e sugli **stessi target**.

TRE: la metrica primaria

5 target lungo la regione cervicale centrale, vicino al **midollo** (la struttura da non danneggiare).

$$e_k = \| R_{pred} R_{gt}^T (p_k - t_{gt}) + t_{pred} - p_k \|$$

Metriche secondarie: errore di rotazione (°), di traslazione (mm), source proxy (diagnostico). Per ognuna: media, std, mediana, p95, max.

Correttezza verificata con casi noti: SVD senza rumore, TRE nullo, traslazione di 1 mm, rotazione di 90°.

STEP 8

Supervisione geometrica delle corrispondenze

La sola pose loss supervisiona l'uscita finale ma **non obbliga l'attenzione** a rappresentare corrispondenze geometricamente sensate.

Etichette soft dalla ground truth:

$$q_{ij} = \mathrm{softmax}_j\left(-\|R_{gt}x_i + t_{gt} - y_j\|^2 / 2\sigma^2 \right), \ \sigma = 5\ \mathrm{mm}$$

$$L_{corr} = D_{KL}(q \,\|\, p), \quad p_{ij} = \mathrm{softmax}_j(S_{ij})$$

$$L_{tot} = L_{pose} + 0.1 \cdot L_{cycle} + \lambda_{corr} \cdot L_{corr}$$

- La GT serve **solo a costruire la loss**, mai come input della rete.
- Non serve che source e target contengano gli stessi punti.
- Il miglior checkpoint è scelto sulla **pose validation loss** (senza KL), per non premiare buone corrispondenze con una posa peggiore.
- Implementata in `correspondence_loss.py`; logits esposti da `return_correspondence`.

STEP 9

Riproducibilità e protocollo sperimentale

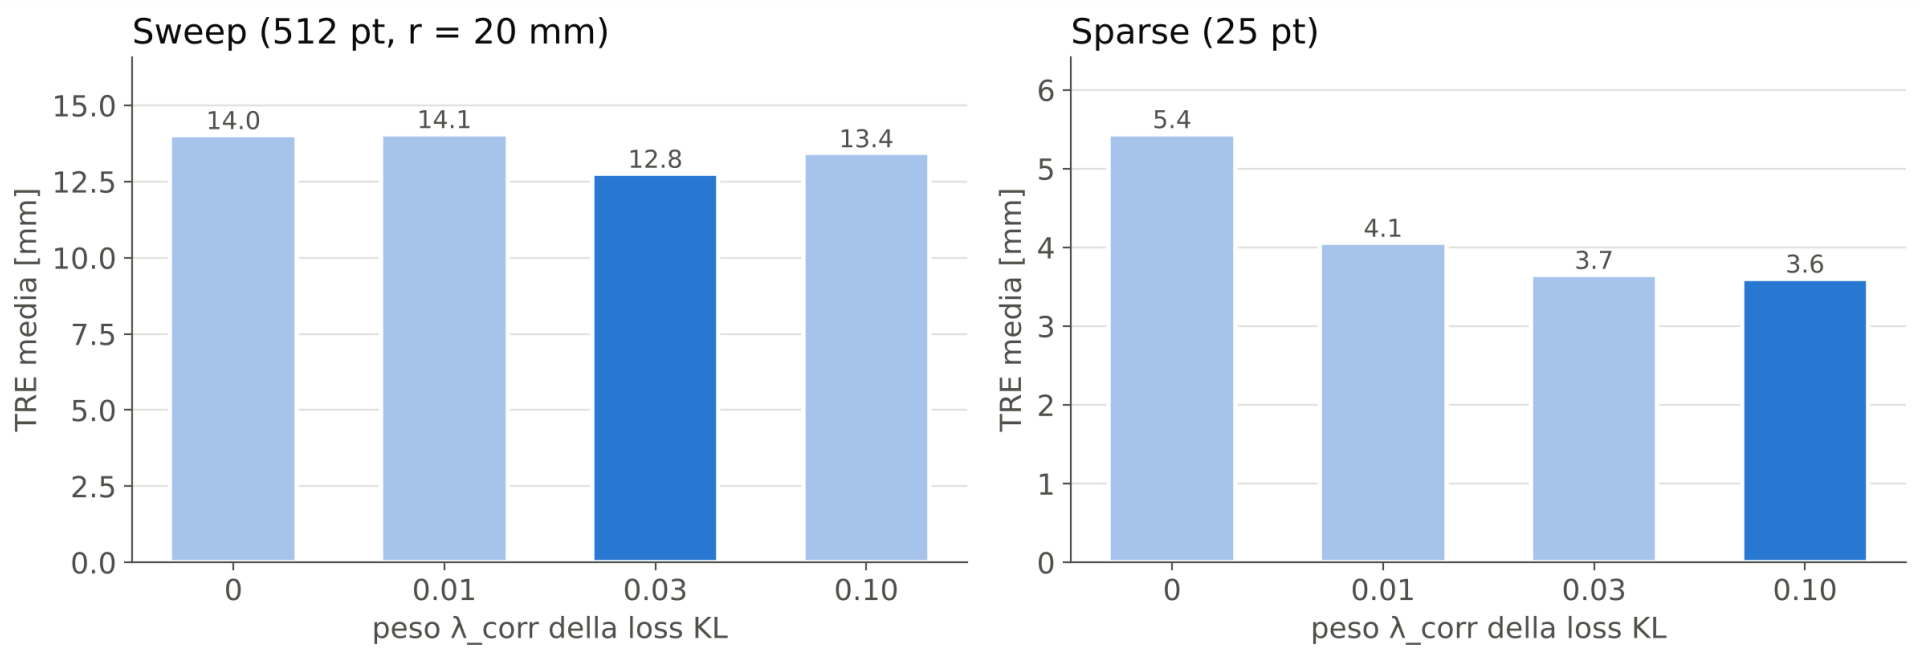
Controlli aggiunti

- Seed deterministico per campione: `SeedSequence([seed, index])`, split separati.
- Checkpoint con argomenti, optimizer, scheduler, epoca, digital twin e hash SHA-256 della mesh.
- `--resume` distinto da `--pretrained`; blocco sovrascrittura esperimenti; backup dei sorgenti.
- **8 unit test** (`test_correspondence.py`): forward/backward, scala, permutazioni, corrispondenze, checkpoint, dataset, SVD, TRE — tutti superati su Windows e Linux (GPU).

Parametro	Valore
Training / validation	5000 / 500 campioni
Development set	2000 campioni, seed 44
Epoche	50 (StepLR ×0.5 dopo 25)
Ottimizzatore	Adam, lr 10^{-3}, wd 10^{-4}
Batch size	2
Rotazione / traslazione max	±9.7° / ±10 mm per asse
Rumore	σ = 0.3 mm
Target	1024 pt FPS

STEP 10 · RISULTATI

Ablation 1: quanto pesare la loss geometrica?

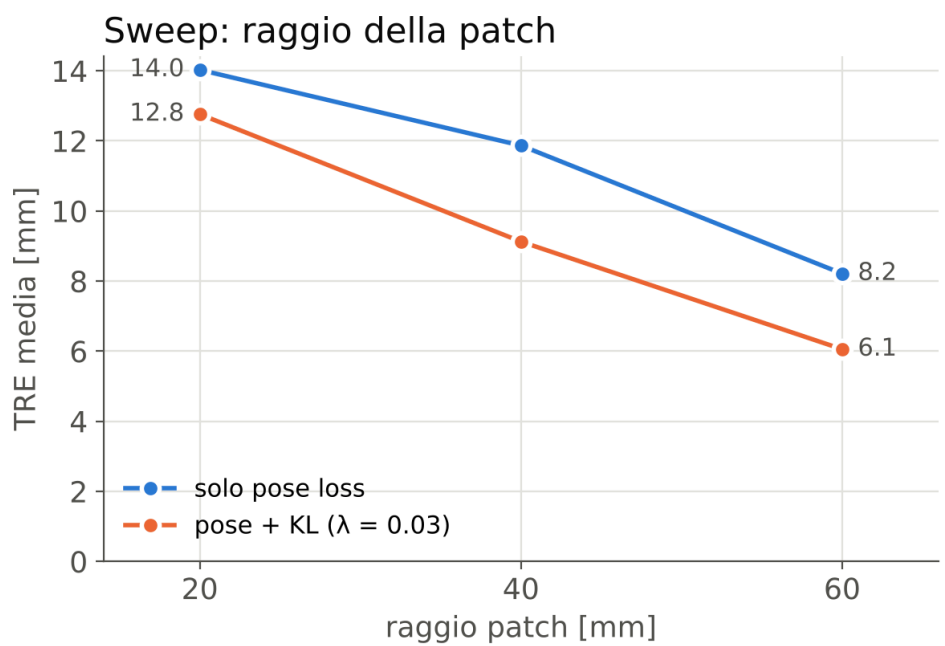


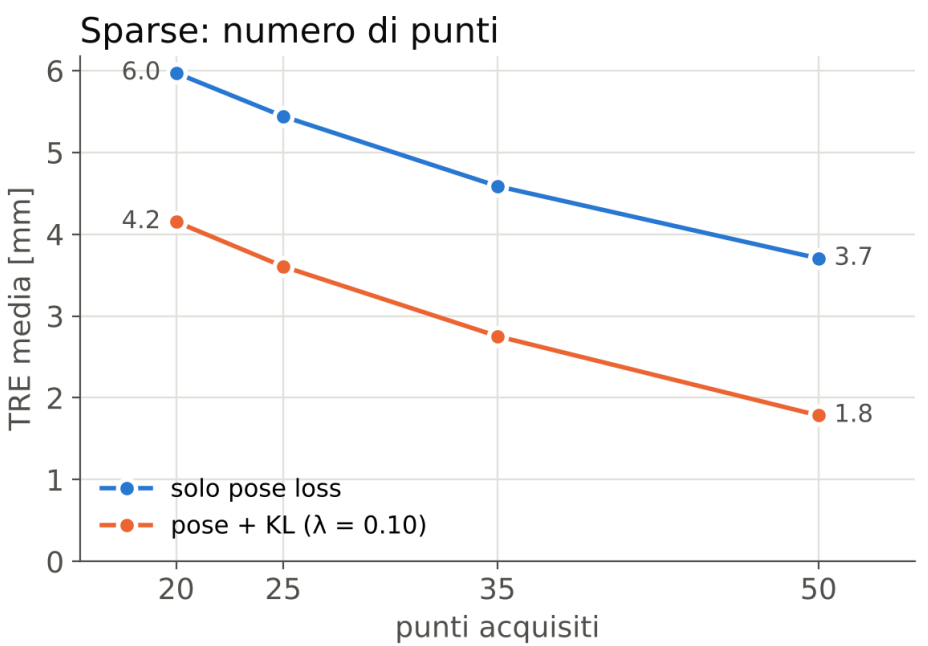
Sweep: λ = 0.03 è il compromesso migliore: TRE media −9% (14.0 → 12.8 mm), mediana −13.5%. Con λ = 0.10 migliora il proxy ma peggiorano p95 e massimo (90.5 mm).

Sparse: miglioramento netto e monotono fino a λ = 0.10: TRE media −33.7% (5.4 → 3.6 mm), mediana −37.4%, p95 −26%.

STEP 10 · RISULTATI

Ablation 2: come acquisire i punti?





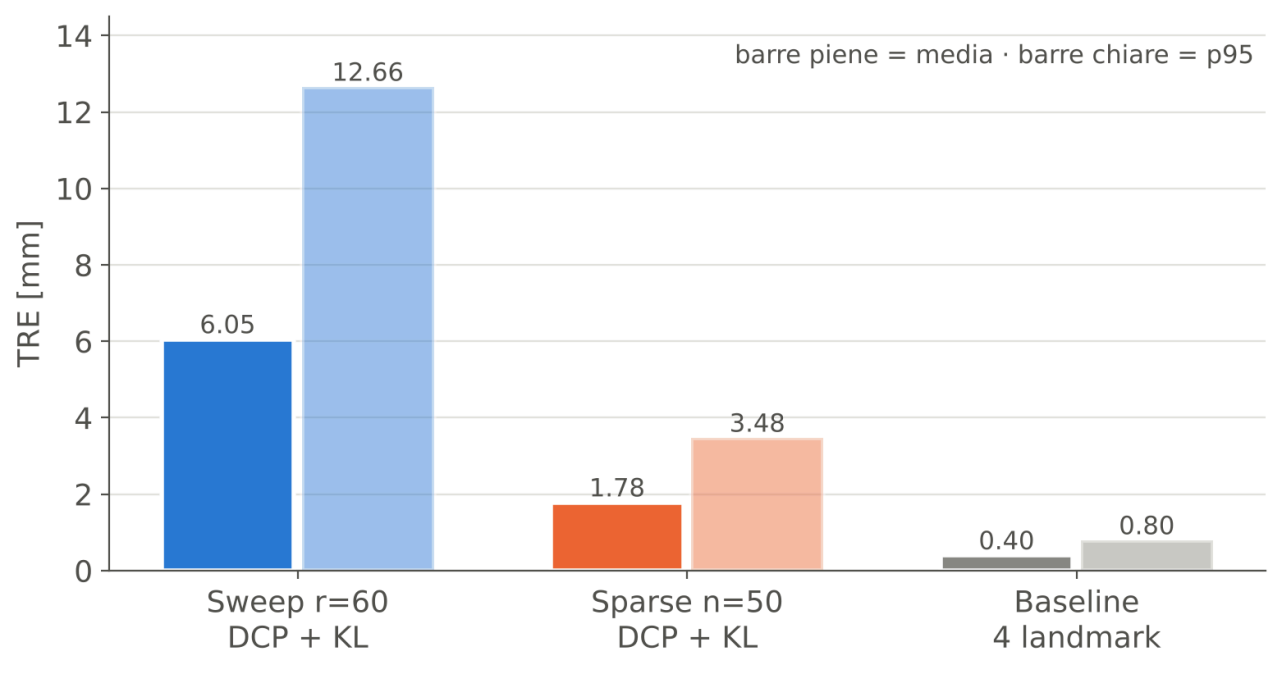
Sweep: allargare la patch da 20 a 60 mm più che dimezza la TRE (12.8 → 6.1 mm con KL). La KL aiuta a ogni raggio.

Sparse: più punti → meno errore. Con 50 punti e KL: **TRE media 1.78 mm**, p95 3.48 mm.

Perché 25 punti sparsi battono 512 punti sweep? Lo sweep è una singola patch locale, spesso liscia o quasi simmetrica: molti punti vicini aggiungono poca informazione globale. Pochi punti distanti vincolano meglio rotazione e traslazione.

RISULTATI

Confronto con la baseline a 4 landmark



Metodo	Rot. [°]	Trasl. [mm]	TRE [mm]
Sweep r=60, DCP+KL	4.31	6.01	6.06
Sparse n=50, DCP+KL	**1.64**	**2.07**	**1.78**
Baseline 4 landmark	0.43	0.56	0.40

La baseline resta **più accurata** (≈4× sulla TRE rispetto al miglior DCP), ma richiede identità e ordine dei 4 punti.

DCP lavora con punti **arbitrari e non ordinati**: un problema intrinsecamente più difficile.

RIEPILOGO

Problemi incontrati e soluzioni

Problema	Soluzione	Conseguenza
Source e target identici	Permutazioni, campionamenti indipendenti, target globale FPS	Niente corrispondenze implicite; problema realistico
Metriche punto a punto	Posa predetta e GT applicate agli stessi punti	MSE/MAE invarianti all'ordine
Cardinalità diverse	Attenzione $N_s \times N_t$ e target virtuali	25 / 512 punti contro 1024
Gap train/eval, batch piccoli	BatchNorm → GroupNorm	Checkpoint più affidabili
Digital twin ricampionato	Target FPS fisso salvato nel checkpoint	Riproducibilità train/val/test
Unità mm vs rete	Scala unica + conversione esplicita	Errori fisici interpretabili
Baseline con vertici casuali	Landmark ufficiali + SVD dei docenti	Confronto difendibile
Attenzione non supervisionata	KL geometrica con etichette soft	Forte miglioramento, soprattutto sparse
Esperimenti sovrascrivibili	Blocco cartelle, backup sorgenti, best/last	Tracciabilità

CONCLUSIONI

Cosa abbiamo imparato

1. Pipeline completa e verificata per la registrazione **partial-to-global**, non ordinata, del phantom cervicale.
2. La **supervisione geometrica** delle corrispondenze aiuta sempre, soprattutto in modalità sparse.
3. Pochi punti **distribuiti globalmente** sono più informativi di uno sweep locale denso.
4. La baseline a 4 landmark resta più accurata, ma paga con **corrispondenze e ordine prescritti**.

1.78 mm

TRE media migliore (sparse, 50 punti, DCP + KL)

0.40 mm

TRE media baseline 4 landmark

La domanda giusta non è "DCP batte la baseline?", ma **quanto errore siamo disposti ad accettare per eliminare la procedura vincolata**, e con quale modalità di acquisizione il compromesso è più favorevole.

PROSSIMI PASSI

Validazione ancora da completare

Multi-seed

Ripetere le 4 configurazioni principali con ≥ 3 seed di training (es. 42, 123, 777): media e deviazione tra seed.

Test held-out

Seed 314159 riservato alla sola valutazione finale, mai usato nelle scelte progettuali.

Bacino di convergenza

Aumentare rotazioni e traslazioni iniziali, success rate con soglia TRE fissata a priori (es. < 5 mm).

Robustezza al rumore

σ = 0, 0.3, 0.6 mm: separare l'ambiguità geometrica dall'errore del tracker.

Reality check Polaris

Piccolo set di acquisizioni reali sul phantom fisico: calibrazione, contatto, occlusioni, campionamento manuale.

Superficie acquisibile

Confermare con la docente quale superficie (anatomia interna esposta o scocca esterna) usare nella versione finale.

Grazie per l'attenzione

Domande?

[1] K. S. Arun, T. S. Huang, S. D. Blostein, "Least-Squares Fitting of Two 3-D Point Sets", IEEE TPAMI, 1987.
[2] Y. Wang, J. M. Solomon, "Deep Closest Point: Learning Representations for Point Cloud Registration", ICCV 2019.
[3] P. J. Besl, N. D. McKay, "A Method for Registration of 3-D Shapes", IEEE TPAMI, 1992.
[4] Y. Wang et al., "Dynamic Graph CNN for Learning on Point Clouds", ACM TOG, 2019.
[5] A. Vaswani et al., "Attention Is All You Need", NeurIPS 2017.